



北京大学数字人文研究中心
Digital Humanities Center

第四届东亚古籍数字人文国际论坛

4TH Annual International Conference on Digital Humanities for East Asia Classics

论文集

2025 年 7 月

北京大学数字人文研究中心 主编

目录：

子论坛 1：大模型应用

AI-Driven Rediscovery of Zhuangzi’s Sitting in Forgetfulness: A Quantitative Analysis Based on Terminological Evolution and Cross-Textual Linkages 1

多模态视域下的古籍版面数字化研究整理 1

基于推理模型的唐诗生成研究 2

基于优化元学习的藏医药领域实体关系联合抽取方法研究 3

融合提示工程与 RAG 的东亚非汉文文献翻译研究：候文汉译的跨语言实践 5

推理大语言模型在古籍智能信息处理上的性能评测研究 6

子论坛 2：古典文献

从古典到数智：类书知识组织体系的重构 7

国内数字人文视域下文献辨伪研究的回顾与探索 7

《红楼梦》版本传承关系及其可视化研究 7

以数据解读韩国经学资料：以《尚书古训》为对象的语义数据编纂与分析 9

「異書」與「子史」新解：從書籍光譜與書目統計重審六朝圖書世界的變容 10

藏文长条卷古籍的分类整理与共享机制探索 10

以位解易：数字人文视域下儒门易学“爻位说”阐释范式研究 11

子论坛 3：文化遗产

Empowering "Same-Melody Lyric Writing" with AI Virtual Singers: A Path to the Revitalization of Chinese Traditional Poetry Cultural Heritage 13

基于博物馆文物数据知识图谱构建的儿童严肃游戏叙事生成路径探索 13

交互隐喻与数据可视化的文化转译 —— 基于 Bauhaus、Muslims in Brooklyn、Connections 多模态融合的时空叙事解析 16

文化基因视域下丝绸之路文献遗产知识组织研究 17

基于本体的中国传统手工纸知识图谱构建研究 18

子论坛 4：资源与人才建设

AI 时代专业图书馆特色古籍语料库建设价值与路径研究 20

构建韩国汉诗数据库的概念数据模型初探 21

古籍数字化标准实践路径研究 22

藏医药古籍数字化人才培养新模式研究 24

子论坛 5：计算文学

被观看的面容：中国古代妆容图谱作为数字客观性技术的女性身体再现批判 26

基于词汇语义特征的风格计量研究 —— 以李杜诗歌为例 27

基于文本挖掘和主题网络分析的唐宋潮汕流寓文学研究 27

《朋旧及见录》与清中期诗人关系网络及其诗歌风格探析 28

基于数字人文技术的唐诗宋词“天涯”意象多维度研究	28
形神相得：数字人文视域下李奎报唐诗接受研究	29
 子论坛 6：历史地理	
丹青事业：数字人文视域下的张宝《泛槎图》文化生成考	30
基于历史文本的区域关系挖掘：以明代中国的地方网络为例	33
基于语义嵌入与网络中心性的中国文化中心建模	34
大语言模型驱动下的北京中轴线空间叙事知识图谱构建	36
历史功能分区下的租界建筑色彩分异 —— 以上外滩和衡复历史风貌区为例	36
数字人文视域中近代北京城市空间形态的历史影像分析研究	38
 子论坛 7：古籍智能处理	
基于 BERTopic 主题模型的《四库全书总目》类书提要评语分析	40
基于大模型强化学习的文化遗迹史料事件抽取方法研究	41
基于古籍文献循证的罕见病知识多维度聚合与实证研究	43
基于术语向量知识库检索增强生成的古代典籍机器翻译研究	44
Multilingual OCR Development for Early 20th Century Korean Documents	44
 子论坛 8：数字东亚	
Current Status and Prospects for the Construction of Ancient Japanese Dictionaries and Vocabulary Databases	45
断指与疗亲：朝鲜社会的医疗观念之一	49
Mapping Dissent: Intellectual Networks, Cultural Production, and Revolutionary Discourse in Late Qing Lingnan	50
人工智能在辅助翻译与传播东方经典文献中的作用与潜力	52
日本古代辞书数据库门户系统的初步建设	52
水书文字数据库和识别平台	54
 子论坛 9：平台建设	
段玉裁《说文解字注》知识库的构建与应用	55
古籍版本语义模型构建研究	58
江山留胜迹：古籍方志中的文学景观数字化平台建设	60
“明代集部文献全文数据库”建设的思考与实践	60
县级古城文化遗产数字化保护研究 —— “中华古城数字图谱平台”的建设	61
学科交叉融合视域下的中国古陶瓷知识服务平台建构	62

子论坛 10：古籍活化

公共文化数据的 AIGC 数字化机制 —— 基于《秦淮志》可视化创现的人工智能古籍实践 63

古籍文化沉浸式传播的数字场域建构 —— 以《永乐大典》VR 为例 64

基于古籍文献挖掘的清宫可移动文化遗产数字化保护研究 64

基于智能体的古籍知识图谱自动化构建方法研究 —— 以《永乐大典》为例 64

人工智能活化浙江图书馆馆藏人物画的研究 66

“子曰”：中国思想家 —— 孔子 66

子论坛 11：计算语言方法

《红楼梦》作者问题研究 —— 基于 LTP 库依存句法分析和特征提取 68

基于定量互文分析的“在明明德”古代哲学命题探索 68

利用 Wordnet 比较古代语言的词汇系统：上古汉语 - 古希腊语 - 科普特语 69

文体如何“载道”：基于知识图谱的古文运动转型研究 69

数字人文视域下基于语料库与知识图谱的跨时空识字教材对比研究 70

子论坛 12：VR 与声档

潮剧唱本事件关系与叙事要素可视化 71

From Disconnection to Reconnection: AI-Based Digital Storytelling Communication for Cultural Heritage Artifacts 73

Poetic Journeys: Enhancing Intercultural Understanding of Classical Chinese Poetry through VR Landscape 74

音乐档案文献的活化应用研究 —— 以天平乐府奈良正仓院复原乐器演奏团为例 77

子论坛 13：数字文史

朝鲜后期僧人法脉网络图设计 79

徽州诉讼文书领域知识图谱构建研究 80

基于大型语言模型的宋代自然灾害史料智能化解析与知识图谱构建研究 —— 以《宋会要辑稿》为中心 81

数字人文视阈中的宋明美学演变研究 83

中国古代士人兄弟人名用字规律的定量研究 —— 以 CBDB 为中心 83

海报专场 84

说明：

本次会议所收录的论文全文提供给合作期刊编辑进行审阅遴选。论文集仅刊载论文的摘要信息。如需查阅全文，敬请直接联系通讯作者获取（摘要信息附有作者邮件地址）。

基于 BERTopic 主题模型的《四库全书总目》类书提要评语分析

余雨^{1,*}, 何晋豪²

¹暨南大学中国语言文学系博士生 广州

²香港科技大学(广州)系统枢纽博士生 广州

* 通讯作者: yuyuabby1997@163.com

关键词:

BERTopic; 《四库全书总目》; 类书提要

正文:

类书作为汇编资料、分部别居的书籍形式,凭借其广博的内容与系统的体例,被誉为中国古代的“百科全书”。《四库全书总目》是清代官方对历代学术的高度总结,其提要部分包含四库馆臣对各部各类典籍的评价与学术观点。其中类书类及其存目有 278 篇提要,评价词汇丰富,体现了馆臣对类书的看法和情感倾向,为研究类书的学术地位提供了线索。传统文学及文献研究常用文本细读与文献分析法探讨《总目》类书提要,这种路径易受研究者主观视角的偏差影响,且难以把握类书提要的整体性。BERTopic 主题模型基于预训练语言模型,能够在深入理解复杂文本含义的基础之上,通过密度聚类自动划分主题簇,并依据簇内词频或语义相似性自适应地生成主题关键词。这一技术用于分析《总目》类书提要时,能够深入到主题语义关系层面进行挖掘,同时避免人为干预所导致的偏差,从而较为精准地提取四库馆臣的类书评价关键词,以此系统总结他们对类书的基本看法以及理想类书的特点,并为深入理解中国古代知识体系提供有益的学术参考。

本研究的研究过程包含五个步骤。一,数据获取。通过网络爬虫技术抓取文渊阁本《总目》类书提要的正文,并利用中华书局 1965 年版《总目》对电子文本进行校对,修正错误字词,得到可靠的文本。二,文本标注。在前述基础上对提要文本进行元数据标注,标注内容涵盖编目、书名、时代、原文、评语、情感色彩等信息。其中重点为情感色彩标注,剔除情感倾向较为模糊或无明显情感表达的 28 篇提要,将剩余提要分为褒义组(69 篇)与贬义组(181 篇),以便后续分别进行主题分析。三,大语言模型转译。考虑到《总目》类书提要相较于普通古代汉语文本具有特殊性,如用典繁多、表述简略晦涩等,而 BERTopic 的中文语料预训练主要基于现代汉语,在处理类书提要时存在语义模糊性问题。同时,类书提要大量使用同义词,例如形容书籍陋劣有“拙陋”“荒陋”“谬陋”“猥陋”等多种表达,这些同义项在主题建模过程中无法提供清晰的词语输入。因此,在进行主题识别前,借助大语言模型将类书提要在不丢失古代汉语原文核心评价信息且保留原文情感的基础上转译为现代汉语,以改善语义理解。四,将经过大语言模型转译后的褒义评语与贬义评语分别输入 BERTopic 进行主题聚类。具体建模步骤包括预训练模型嵌入向量提取、降维和聚类、文本主题预测、基于嵌入向量相似性的聚类噪声去除、TF-IDF 主题词提取等环节。五,根据 TF-IDF 方法所提取的主题关键词进行人工抽象概括,运用主题可视化技术以及主题演化分析方法,揭示《总目》类书提要中所蕴含的四库馆臣类书取向,探寻类书在中国古代学术评价体系中的地位。

研究显示, BERTopic 共提取出 6 组贬义主题,按代表性高低排序为:抄袭杜撰、不注出处、不重考证、拼凑割裂、内容粗陋、缺乏学术价值。这些负面主题多涉及类书的成书方法、引书特征和内容价值。其中,“抄袭杜撰”主题相关文档占比最高,表明此类负面特质最常被提及,“抄袭杜撰之书”是馆臣对类书的基本评价。褒义主题共 5 组,按代表性高低排序为:详注出处、保存原文、摘取详尽、具备学术或实用价值、补足史书缺失。以上褒贬主题可互相对照,如贬义提要中,“不注出处”所包含文档数量排列第二,而在褒义提要中,“详注出处”所包含文档数量排列第一,可见对于材料来源是否有详细的、规范的说明,是馆臣评价类书时一项相当重要的标准。综合各褒贬主题,可以归纳四库馆臣的理想类书特点:详实的出处标注;对材料原文的完整保存和详尽的内容摘取;具备学术深度或经世价值;严谨的考证;独立的见解。此外,评语的主题演化趋势图显示馆臣对类书的褒贬存在明显的阶段性变化,存在突出的厚古薄今倾向。宋代类书提要的褒义主题最为集中,它们被认为在整体上质量最高。元代类书的褒贬倾向皆不突出,整体受重视程度较低。负面评价高度集中于明代,其中最为突出的负面主题是“抄袭杜撰”“不注出

处”“不重考证”。而清代类书受批评的程度仅次于明代类书。总体而言，四库馆臣对类书持否定态度，其中以明清类书最受贬斥。这既受到中国古代重视思想性著作而轻视知识性著作的学术传统影响，也与清代官方对明代学风及其流弊的批判有关。

本研究以新方法 BERTopic 模型对《总目》类书提要进行分析，着眼于整体视角，借助可视化数据，探讨了四库馆臣的类书思想。但是研究也面临诸多阻碍，BERTopic 模型及中文分词工具如 Jieba、Jiayan 等对古汉语的识别度有限是关键瓶颈。本研究以《总目》类书类一及类书类二中提要评语的人工标注结果作为真值，检验 Jiayan、Jieba、HanLP 三种常用中文分词工具的分词性能，测试结果如下表所示：

分词工具	Jiayan	Jieba	HanLP
P (准确率) [1]	0.34	0.47	0.47
R (召回率) [2]	0.45	0.54	0.58
F1 值 [3]	0.38	0.5	0.51

P (Precision)：表示分词系统识别出的词语中正确词语的比例。

R (Recall)：表示分词系统识别出的词语中正确词语的比例相对于所有实际词语的比例。

F1 值：综合考虑准确率和召回率的一个指标，用于平衡两者之间的关系。其计算公式为

$F1 = (2 \times Precision \times Recall) / (Precision + Recall)$ 。在分词评估中，F1 值越高说明分词系统在准确率和召回率之间达到了越好的平衡，分词效果越佳。

在分词工具性能测试中，Jiayan、Jieba、HanLP 的 F1 值均处于较低水平，说明三者对于《四库全书总目》类书类提要的分词结果均不理想。鉴于此，本研究需将提要原文转译为现代汉语后进行主题聚类。此举虽增强了 BERTopic 的文本识别率，却丢失了原文评价词，使得聚类关键词的直观性受损。展望未来，文科学者在使用新数字工具的同时，更应探索如何优化工具，以提升其适用性。以中国古代文学与古典文献学为例，目前针对复杂古代汉语文本进行分词标注、主题提取的可靠工具还较为缺乏。如何丰富古代汉语语料库，使数字技术攻破古代汉语模糊词义和灵活语法难题，改进现有分析工具，是未来应深思的研究方向。

基于大模型强化学习的文化遗迹史料事件抽取方法研究

高鑫¹，张卫^{2*}，刘浏³，王东波⁴

¹南京农业大学信息管理学院硕士研究生 南京

²南京农业大学信息管理学院钟山青年研究员 南京

³南京农业大学信息管理学院副教授 南京

⁴南京农业大学信息管理学院教授 南京

* 通讯作者：qwzhang@njau.edu.cn

关键词：

数字人文；文化遗迹；事件抽取；大模型强化学习

正文：

【动机】

文化遗迹（或称“不可移动文物”“文物古迹”）是具有历史价值、科学价值、艺术价值、遗存于社会空间内的文化遗产或遗址 [1]。在人类与各类古建筑、聚落、景观的长期社会交互中，留存下了众多文化遗迹档案文献、方志书籍、考古记录、碑帖拓本等宝贵史料资源。随着数字人文学科与 AIGC 技术的与日俱新，文化遗产智能计算研究工作得到了快速发展，采取前沿自然语言处理方法对领域非结构化文本中的叙事语义特征进行细粒度知识挖掘与关联，能够有效赋能文化遗产历史知识检索、智能问答、数字叙事 [2]，继而从数据智能维度促进中国特色哲学社会科学体系建构。

【目标】

本文旨在传统事件抽取范式的基础上对文化遗迹史料资源内的叙事特征进行语义挖掘。对此，笔者首次引入了事件关键短语这一知识单元，通过一个描述事件信息的主谓宾式短语或短句结构对原完整史料句进行事件知识表示，并重点结合叙事逻辑定义了短语的细粒度知识体系：<施事主体论元（Agent），触发词及其事件类型（Trigger/Class），受事客体论元（Patient）>。例如，事件关键短语命名为“张学良拜谒中山陵”，其内嵌知识体系设计为：<张学良（Agent），拜谒（国家政治）（Trigger/Class），中山陵（Patient）>。为此，本文基于事件关键短语及其知识体系构建文化遗迹叙事文本语料库，通过 AIGC 技术训练事件抽取模型与实体叙事化关系抽取模型。最近，以强化学习驱动的大型语言模型（如 Deepseek-R1-671B、Qwen3-235B-A22B 等）在自然语言处理方面表现卓越 [3]，但其庞大参数量导致部署和 API 调用成本高昂。因此，知识蒸馏技术成为关键，它能将大模型知识有效迁移至小模型 [4]，同时结合拒绝采样方法 [5]，在少量标注数据条件下优化性能，为垂直领域 NLP 任务提供了高效解决方案。因此，本文旨在通过大模型知识蒸馏技术、拒绝采样、强化学习技术训练文化遗迹事件关键短语抽取模型及内嵌论元实体间的叙事化关系抽取模型，同时验证事件分类、论元抽取等常规事件抽取子任务的实验效果。通过有监督微调、以及 GRPO（Group Relative Policy Optimization）强化学习方法 [6] 提升领域模型在事件抽取任务上的性能。

【过程】

本文事件抽取核心任务包括：①事件关键短语抽取，识别描述事件的非连续行文短语结构，其在触发词识别基础上进行扩展，融入事件关键论元提升知识单元的富语义性，可视为短语（句）层面的文本摘要任务；②实体叙事化关系抽取，对事件关键短语中的施事论元与受事论元间的叙事关系进行语义判别，可视为关系分类任务；③常规事件抽取子任务，包括事件分类与事件论元识别等 [7]。对此，本文结合文本处理与专家分析等方式预先确立了事件分类体系（国家政治、战争军事、建筑修造、组织规划、文物损毁、考古发掘、荣誉成就、习俗礼教、社会活动、人类生活）与论元角色（时间、文物、人物、组织、地点、设施、职位、奖项、国家、集会、军队、自然、作品、战争、规划法约）。整体实验过程如下：

（1）基于 Deepseek-R1-671B 进行 Few-shots 知识蒸馏。设计 Few-shots 为基础的 Prompt 模板，利用 Deepseek-R1-671B 对于文化遗迹叙事文本进行自动标注，以获取事件关键短语及其内嵌论元、触发词的伪标签。

（2）遗迹事件抽取学习语料库质量优化。邀请 1 名历史学专家（指导员）和 3 名数字人文领域研究生（审核员）组成标签审核小组，对于上一步得到的伪标签进行校对审核，优化语料库质量水平。

（3）大模型推理知识引导的事件抽取小模型冷启动。根据校对审核之后得到的高质量语料库，设计事件抽取核心任务与常规事件抽取子任务 Prompt 模板对选取的较小参数模型进行指令微调冷启动。最终合并 LORA 权重与原始模型，得到指令微调冷启动模型。

（4）拒绝采样思想驱动的语义关系抽取小模型强化学习训练。根据冷启动模型，我们对实体语义关系抽取任务实施 GRPO 训练，设计了全面的奖励函数评估系统：①完整性奖励（20%）：衡量三元组结构的完整性，缺失元素将相应扣分；②准确性奖励（60%）：评估每个元素与标准答案的精确匹配程度，对完美匹配设置额外奖励；③部分匹配奖励（15%）：通过 Jaccard 相似度计算字符级和词级重叠率，为语义相近的非完全匹配结果提供评分；④格式奖励（5%）：确保输出为可解析的规范 JSON 格式；所有奖励经加权计算并归一化为 0-1 分值，作为 GRPO 训练的优化信号。

（5）模型评价指标体系设计与模型评测。事件抽取任务评价指标体系：①事件关键短语抽取：采用 BLEU[8]、ROUGE[9] 指标评估短语生成质量；②实体叙事化关系抽取：使用完全匹配准确率（Accuracy）及关键论元与触发词的宏精确率（Macro_P）、宏召回率（Macro_R）和宏 F1 指标评估语义抽取性能；③常规事件抽取：应用准确率（Accuracy）、宏精确率（Macro_P）、宏召回率（Macro_R）和宏 F1 指标评估事件分类性能，同时采用 P、R、F1 指标衡量事件论元识别效果。

【主要结果和结论】

（1）事件关键短语抽取监督微调冷启动。基于事件抽取冷启动训练模型，评测事件关键短语及其内嵌知识体系的抽取效果。其中 DeepSeek-R1-Distill-Qwen-32B 抽取事件短语的效果最为出色，BLEU-1 和 ROUGE-1- F1 值分别为 78.77%、83.55%。QwQ-32B 在事件分类取得最佳实践（Accuracy=85.09%）。Qwen3-32B 在触发词抽取和受事者抽取上展现了优越的性能，F1 值分别达到 95.46%（触发词抽取）和 88.09%（受事者抽取），Qwen2.5-32B-Instruct 在施事者抽取上展现最优性能（F1=89.55%）。三元组抽取任务中，综合性能最佳的是 Qwen2.5-32B-Instruct（Accuracy=75.65%；Macro_F1=90.93%）。所有模型在经过监督微调训练之后均相较于基线模型

(2) 实体语义抽取模型强化学习。经过 GRPO 训练的 GRPO_Qwen3-32B, 在测试集上取得最佳实践 (Accuracy=76.65%; Macro-F1=91.58%), 同时相对于冷启动监督微调的 SFT_Qwen3-32B (Accuracy=75.40%; Macro-F1=90.88%), 准确率提升了 1.25%。此外, 大部分模型在经过 GRPO 训练之后, 准确率和 Macro-F1 得到提升, 其中 GRPO_DeepSeek-R1-Distill-Qwen-32B 的准确率从 66.34% 跃升至 76.15%, 最为显著。由此可见, 强化学习训练在少量训练样本下可以对大模型性能进行显著优化。

本研究在引入事件关键短语这一知识单元的基础上, 提出了基于大模型“知识蒸馏 + 拒绝采样”的文化遗迹史料事件抽取方法, 通过 AIGC 技术对事件短语(句)与短语内的实体级内嵌结构进行语义挖掘与解析, 实现了文化遗迹史料内多粒度知识单元的叙事化语义关联与分析。本文工作通过前沿大语言模型技术的应用丰富了事件抽取、关键短语抽取等自然语言处理领域的方法体系, 而多粒度事件知识单元的语义组织模式可为文化遗产数字化保护与智能计算等数字人文研究提供理论借鉴。

基于古籍文献循证的罕见病知识多维度聚合与实证研究 *

(本文为国际合作项目 InterPARES (电子系统中文件真实性永久保障国际合作项目)TrustAI 子项目“面向医药古籍保护的可信知识图谱自动构建技术与开源应用”(Automatic construction and open source use of trustworthy knowledge graph of ancient Chinese and Italian medical texts)、国家社科基金 2021 年度重大项目“国家重大突发事件信息公开质量研究”(项目编号: 20&ZD141)和 2024 年中国科学技术信息研究所情报工程实验室开放基金“面向大语言模型检索增强的科技文献深度挖掘研究”成果之一。)

宋培彦¹ 鲁婷^{2*} 胡博深²

¹ 天津师范大学管理学院数据科学系教授 天津

² 天津师范大学管理学院数据科学系情报学硕士研究生 天津

* 通讯作者: songpy@tjnu.edu.cn

摘要:

罕见病成为全球医疗领域的重大挑战, 中医古籍中蕴含的丰富医学知识为罕见病治疗提供了潜在解决方案, 但古籍文献具有数据分散性、语言复杂性与知识专业性等特点, 限制了其有效利用。为此, 本文采用古籍文献循证理论开展古籍罕见病知识组织与知识发现研究, 构建“多源整合 - 语义计算 - 循证服务”数据挖掘与分析框架, 结合自然语言处理技术探索古今疾病关联, 为罕见病可信知识发现提供技术支撑。具体过程是: 首先, 构建了罕见病古籍数据集, 收集了罕见病中文名称、英文名称、121 种罕见病相关病症描述以及罕见病相关信息, 对中文名称以及相关病症描述, 并收集了《诸病源候论》等古籍文献进行标准化整理并存储, 对罕见病的中英文名称、临床表现、诊疗信息等进行结构化整理, 形成罕见病专题数据集。其次, 采用 BERT-base-chinese 模型对病症描述进行向量化表示, 利用余弦相似度算法计算中西医病症的语义相似度, 建立罕见病与中医疾病名称关联网络; 然后, 从古籍文献中提取循证依据, 形成跨时空的知识脉络; 最后利用低代码开发平台搭建了“古道”知识服务系统, 支持罕见病信息检索、可视化展示及古籍原文循证功能。测试结果表明, 以古籍文献作为数据来源进行多维度循证, 形成细粒度、专门化的知识聚合与服务, 不仅能够为当前罕见病知识组织提供理论参考, 构建语义驱动的多维度知识聚合和横向关联, 而且能够与古籍文献纵向贯通, 形成完整的证据链和可信知识脉络, “古为今用”, 推动古籍医学知识有效活化与可信服务。

关键词:

医学古籍; 知识组织; 知识发现; 文献循证; 罕见病



DHEAC2025